



UNIVERSIDAD
DE BURGOS



Trabajo Fin de Máster

Máster Universitario en Ingeniería Biomédica

Evaluación computacional de
nanopartículas poliméricas y
dendrimeros como sistemas de liberación
de fármacos: acoplamiento molecular con
proteínas de barrera biológica y modelos
predictivos de eficiencia de transporte

Presentado por **Diego Vallina Álvarez**

Universidad de Burgos · Curso académico 2025–2026

Directores:

Santiago Aparicio Martínez

Pedro Ángel Marcos Villa



UNIVERSIDAD
DE BURGOS



D. Santiago Aparicio Martínez, profesor del Departamento de Química, Área de Química Física, Unidad de Investigación Consolidada 305 — Análisis y Simulación Molecular de Fluidos, Universidad de Burgos.

D. Pedro Ángel Marcos Villa, profesor del Departamento de Química, Área de Física Aplicada, Universidad de Burgos.

Exponen:

Que el alumno D. Diego Vallina Álvarez, con DNI 58441105Z, ha realizado el Trabajo Fin de Máster en Ingeniería Biomédica titulado:

Evaluación computacional de nanopartículas poliméricas y dendrímeros como sistemas de liberación de fármacos: acoplamiento molecular con proteínas de barrera biológica y modelos predictivos de eficiencia de transporte.

Y que dicho trabajo ha sido realizado por el alumno bajo la dirección de los que suscriben, quienes autorizan su presentación.

En Burgos, a 8 de junio de 2026

Vº. Bº. del Director:

Vº. Bº. del Director:

D. Santiago Aparicio Martínez

D. Pedro Ángel Marcos Villa

Resumen

Los sistemas de liberación de fármacos basados en nanopartículas poliméricas y dendrímeros representan una de las estrategias más prometedoras en nanomedicina. Su eficiencia de transporte depende fundamentalmente de la interacción de sus componentes moleculares con las proteínas de barrera biológica que regulan la biodistribución, el metabolismo y la captación celular de los fármacos.

Este trabajo presenta una plataforma computacional integrada para la evaluación sistemática de 58 moléculas representativas de monómeros, oligómeros, unidades de dendrímero, fármacos modelo y ligandos de targeting frente a seis proteínas de barrera clave: P-glicoproteína (P-gp/MDR1), CYP3A4, receptor de transferrina (TfR1), receptor de folato alfa (FR α), lisozima y albúmina sérica humana (HSA).

La metodología combina: (i) optimización de geometrías moleculares mediante DFT (B3LYP-D4/def2-TZVP) y cálculo de perfiles sigma COSMO-RS en clúster HPC; (ii) acoplamiento molecular sistemático con AutoDock Vina 1.2.5 (342 dockings) y análisis de interacciones proteína-ligando con PLIP 2025; (iii) cálculo de 2908 descriptores moleculares (2D, 3D, fingerprints y perfiles de polaridad superficial) y propiedades ADMET con SwissADME; y (iv) tres modelos de aprendizaje automático: regresión de afinidad por proteína (Random Forest, R^2 hasta 0.817 para P-gp), un Índice de Eficiencia de Transporte (ITI) y un clasificador favorable/desfavorable (AUC = 0.983). El análisis SHAP revela que la complejidad topológica (BertzCT) es el descriptor con mayor poder predictivo. Los resultados identifican Triethylene glycol (PEG), ramas PAMAM de baja generación y oligómeros de quitosano como los candidatos más favorables para drug delivery, validado estructuralmente por PLIP y farmacocinéticamente por ADMET. El trabajo incluye una herramienta web interactiva (Streamlit) para la recomendación de carrier óptimo a partir del SMILES de una nueva molécula.

Descriptores

nanopartículas poliméricas, dendrímeros, drug delivery, acoplamiento molecular, docking, proteínas de barrera biológica, DFT, COSMO-RS, PLIP, ADMET, descriptores moleculares, aprendizaje automático, Random Forest, SHAP, índice de eficiencia de transporte, P-glicoproteína, receptor de transferrina, receptor de folato

Abstract

Polymeric nanoparticle- and dendrimer-based drug delivery systems represent one of the most promising strategies in nanomedicine. Their transport efficiency fundamentally depends on how their molecular building blocks interact with the biological barrier proteins that govern biodistribution, metabolism and cellular uptake.

This work presents an integrated computational platform for the systematic evaluation of 58 representative molecules — monomers, oligomers, dendrimer units, model drugs and targeting ligands — against six key barrier proteins: P-glycoprotein (P-gp/MDR1), CYP3A4, transferrin receptor (TfR1), folate receptor alpha (FR α), lysozyme and human serum albumin (HSA).

The methodology combines: (i) molecular geometry optimization by DFT (B3LYP-D4/def2-TZVP) and COSMO-RS sigma-profile calculation on HPC; (ii) systematic molecular docking with AutoDock Vina 1.2.5 (342 dockings) and protein-ligand interaction analysis with PLIP 2025; (iii) 2908 molecular descriptors (2D, 3D, fingerprints, surface polarity profiles) and ADMET properties with SwissADME; and (iv) three machine learning models: affinity regression per protein (Random Forest, R^2 up to 0.817 for P-gp), a Transport Efficiency Index (TEI), and a favorable/unfavorable classifier (AUC = 0.983). SHAP analysis identifies topological complexity (BertzCT) as the most predictive descriptor. Triethylene glycol (PEG), low-generation PAMAM branches and chitosan oligomers emerge as the most favorable candidates, structurally validated by PLIP and pharmacokinetically confirmed by ADMET. An interactive Streamlit web tool for optimal carrier recommendation is also provided.

Keywords

polymeric nanoparticles, dendrimers, drug delivery, molecular docking, biological barrier proteins, DFT, COSMO-RS, PLIP, ADMET, molecular descriptors, machine learning, Random Forest, SHAP, transport efficiency index, P-glycoprotein, transferrin receptor, folate receptor

Introducción

Las enfermedades oncológicas, inflamatorias y neurológicas son un problema clínico de primera magnitud. Los sistemas de liberación de fármacos (DDS, del inglés *Drug Delivery Systems*) ofrecen una solución concreta: encapsular el principio activo, protegerlo de la degradación y liberarlo donde hace falta. Las nanopartículas poliméricas basadas en PLGA, PLA o policaprolactona llevan décadas en desarrollo clínico, y los dendrímeros PAMAM, que son moléculas muy ramificadas con cavidades internas para cargar fármacos, representan una alternativa complementaria ([Danhier et al., 2012](#); [Kesharwani et al., 2014](#)).

El problema es que llegar al tejido diana no depende solo del nanocarrier. Hay un conjunto de proteínas que determinan qué le pasa a cualquier molécula que entra en el organismo. La P-glicoproteína (P-gp/MDR1) expulsa los fármacos que reconoce como sustratos, lo que causa resistencia a la quimioterapia ([Waghray and Zhang, 2018](#)). El CYP3A4 los metaboliza en el hígado antes de que lleguen al tumor, y es responsable del metabolismo de más del 50, % de los fármacos clínicos ([Zanger and Schwab, 2013](#)). El receptor de transferrina (TfR1) y el receptor de folato (FR α) están sobreexpresados en las células tumorales y se pueden usar como puerta de entrada para llevar nanopartículas específicamente al tumor. La lisozima es un indicador de compatibilidad tisular. Y la albúmina sérica (HSA) transporta los fármacos en sangre y determina cuánto tiempo circulan.

Evaluar experimentalmente cómo interacciona cada componente de un DDS con estas seis proteínas es inviable a gran escala. El docking computacional, que simula cómo una molécula pequeña se une a una proteína, permite cribar cientos de moléculas antes de tocar un tubo de ensayo ([Trott and Olson, 2010](#)). Los estudios existentes tienen limitaciones claras: se centran en una proteína, trabajan con conjuntos pequeños de moléculas, y ninguno

integra cálculos cuánticos de estructura electrónica para obtener geometrías precisas como punto de partida ([Maingi et al., 2012](#)).

Este trabajo construye una plataforma computacional para evaluar 58 moléculas representativas de nanopartículas poliméricas y dendrímeros frente a esas seis proteínas. Los objetivos concretos son: obtener geometrías moleculares precisas mediante cálculos DFT y perfiles de polaridad superficial (COSMO-RS) en clúster HPC; realizar docking sistemático con AutoDock Vina 1.2.5 y analizar las interacciones estructurales con PLIP 2025; calcular 2908 descriptores moleculares y propiedades ADMET con SwissADME; entrenar modelos de aprendizaje automático para predecir la afinidad de unión y clasificar moléculas para drug delivery; e implementar una herramienta web (Streamlit) que recomiende el carrier más adecuado para una molécula nueva.

Materiales y Métodos

2.1. Base de datos molecular

Se construyó una biblioteca de 58 moléculas en cuatro categorías: monómeros y productos de degradación de polímeros biodegradables (ácido láctico, glicólico, ε -caprolactona y derivados), oligómeros y unidades de dendrímero PAMAM (poliaminas, oligómeros de quitosano), fármacos modelo (doxorubicina, paclitaxel, 5-fluorouracilo, metotrexato, curcumina, cisplatino, gemcitabina, sirolimus, dexametasona, ibuprofeno) y ligandos de targeting activo (ácido fólico, biotina, galactosa, manosa, PEG-aminas y péptido RGD). Los SMILES se obtuvieron de PubChem. Las coordenadas 3D iniciales se generaron con el algoritmo ETKDGv3 y se refinaron con MMFF94 mediante RDKit ([RDKit](#), 2023).

2.2. Optimización de geometrías (DFT)

Los cálculos de estructura electrónica se realizaron con TURBOMOLE 7.8.1 ([TURBOMOLE GmbH](#), 2023) en el clúster HPC CENITS (16 núcleos, 31,GB RAM por nodo). El nivel de cálculo fue el funcional híbrido B3LYP con corrección de dispersión D4 ([Grimme et al.](#), 2010) y base de funciones def2-TZVP ([Weigend and Ahlrichs](#), 2005), con aproximación RI-J para reducir el coste computacional. Para cada molécula se realizaron tres cálculos: (i) optimización de la geometría hasta encontrar la estructura de mínima energía, (ii) cálculo de la distribución de carga superficial (COSMO-RS) para obtener el perfil sigma, y (iii) cálculo de frecuencias de vibración IR para confirmar que la estructura es un mínimo real. El cisplatino requirió un tratamiento especial con pseudopotencial para el platino; el condroitín sulfato, con carga -2 , se recalculó especificando la carga formal.

2.3. Acoplamiento molecular

Las seis proteínas de barrera (Tabla~2.1) se obtuvieron del Protein Data Bank. Las proteínas se prepararon con MGLTools, añadiendo hidrógenos y asignando cargas. Los ligandos se convirtieron a formato PDBQT con OpenBabel. El docking, que simula cómo una molécula pequeña se une a una proteína, se realizó con AutoDock Vina 1.2.5 ([Eberhardt et al., 2021](#)) con parámetros de alta exhaustividad (32), 9 poses por cálculo y 8 CPUs. Las cajas de búsqueda se centraron en los sitios de unión conocidos de cada proteína. De 348 dockings posibles se obtuvieron 342 válidos.

Tabla 2.1: Proteínas de barrera biológica empleadas en el estudio.

PDB	Proteína	Función	Centro grid (Å)
7A65	P-gp/MDR1	Bomba de expulsión de fármacos	160, 177, 144
1TQN	CYP3A4	Metabolismo hepático	-15, 5, -22, 0, -11, 0
1CX8	TfR1	Entrada en células por endocitosis	-28, 4, -38, 9, 147, 7
4LRH	FR α	Internalización del folato	5, 2, 25, 8, -1, 4
1LYZ	Lisozima	Evaluación de biocompatibilidad	17, 0, 10, 0, 25, 0
1AO6	HSA	Transporte en sangre	7, 0, 10, 0, 18, 0

2.4. Análisis de interacciones proteína-ligando

Las interacciones no covalentes entre los cinco candidatos con mayor ITI y las tres proteínas más relevantes (P-gp, TfR1 y FR α) se analizaron con PLIP 2025 ([Schake et al., 2025](#)), una herramienta que detecta automáticamente qué tipo de contactos establece cada ligando con los residuos de la proteína: puentes de hidrógeno, contactos hidrofóbicos, puentes salinos e interacciones entre anillos aromáticos. Se procesaron 15 complejos en total.

2.5. Descriptores moleculares

Se calcularon 2908 descriptores numéricos para caracterizar cada molécula. Se agrupan en cinco familias: descriptores 2D calculados con RDKit ([RDKit, 2023](#)) (38 valores: peso molecular, lipofilia, superficie polar, grupos funcionales, índices de complejidad topológica); perfiles sigma COSMO-RS (100 valores que describen la distribución de polaridad superficial); fingerprints

Morgan/ECFP4 (2048 bits que codifican los patrones de subestructura) y MACCS keys (167 bits) con RDKit; y descriptores 3D calculados con Mordred ([Moriwaki et al., 2018](#)) (1826 valores sobre las geometrías DFT).

2.6. Propiedades ADMET

Las propiedades farmacológicas se calcularon con SwissADME ([Daina et al., 2017](#)) para las 60 moléculas. ADMET es el acrónimo de Absorción, Distribución, Metabolismo, Excreción y Toxicidad. Se obtuvieron 49 propiedades por molécula: cinco modelos de lipofilia (LogP), solubilidad en agua, absorción intestinal, permeabilidad de la barrera hematoencefálica, si la molécula es sustrato de P-gp, inhibición de enzimas CYP450 de metabolismo, score de biodisponibilidad oral, alertas de toxicidad, cumplimiento de las reglas de Lipinski y accesibilidad sintética.

2.7. Modelos de aprendizaje automático

El dataset final tiene 56 moléculas y 2908 descriptores. Antes del entrenamiento se aplica escalado estadístico (RobustScaler) y se seleccionan las 200 variables más informativas para cada proteína (SelectKBest). Se desarrollaron tres modelos:

Modelo 1. Regresión de afinidad: Random Forest (300 árboles), Gradient Boosting (200 estimadores) y SVR (máquina de vectores soporte) para predecir la energía de unión ΔG en cada proteína. Se evalúa con validación cruzada de 5 particiones usando R^2 , MAE y RMSE.

Modelo 2. Índice de Eficiencia de Transporte (ITI): puntuación de 0 a 100 que combina las seis afinidades de docking en una métrica única. Premia la afinidad por TfR1, FR α , HSA y lisozima. Penaliza la afinidad por P-gp y CYP3A4. Incluye un factor corrector por peso molecular.

Modelo 3. Clasificador binario: Random Forest, Gradient Boosting y SVC para clasificar moléculas como favorables (ITI ≥ 50) o desfavorables. Evaluado con AUC-ROC, precisión y F1.

La interpretabilidad de los modelos se analizó con valores SHAP ([Lundberg and Lee, 2017](#)), que miden cuánto contribuye cada descriptor a la predicción final.

Herramienta web. Se implementó una aplicación Streamlit que, a partir del SMILES de una molécula, calcula descriptores, predice el perfil de afinidad

frente a las seis proteínas, calcula el ITI y genera un diagrama radar del perfil de transporte con una recomendación del carrier más adecuado.

Resultados

3.1. Cálculos DFT y perfiles COSMO-RS

Las 58 estructuras moleculares convergieron sin frecuencias imaginarias, lo que confirma que todas son mínimos de energía reales. Los cálculos más exigentes fueron Paclitaxel (113 átomos pesados) y Sirolimus (144 átomos), que requirieron varios cientos de ciclos de optimización. Los perfiles sigma COSMO-RS, que describen cómo se distribuye la carga eléctrica en la superficie de cada molécula, mostraron patrones claros por grupo: los fármacos modelo tienen distribuciones anchas y polares, mientras que los monómeros apolares concentran su densidad de carga cerca de $\sigma \approx 0$.

3.2. Acoplamiento molecular

La figura siguiente muestra la matriz de afinidad completa. Las energías medias de unión por proteína fueron: FR α ($\overline{\Delta G} = -5,70$ kcal/mol), CYP3A4 ($-5,21$), Tfr1 ($-5,08$), P-gp ($-5,07$), HSA ($-4,31$) y Lisozima ($-3,54$). Los valores individuales más negativos, que indican mayor afinidad, fueron Methotrexate en P-gp ($-10,27$ kcal/mol), Paclitaxel en CYP3A4 ($-9,91$) y Folic acid en FR α ($-9,91$). Sirolimus en CYP3A4 obtuvo $-0,15$ kcal/mol, la interacción más débil del dataset, lo que sugiere que esta molécula elude el metabolismo hepático.

Resultados




Figura 3.1: Matriz de afinidad de docking (ΔG modo 1, kcal/mol) para las 57 moléculas frente a las 6 proteínas. Verde oscuro = alta afinidad, rojo = baja afinidad.

El mapa de correlaciones (figura siguiente) muestra que P-gp, Tfr1, FR α y HSA están muy correlacionadas entre sí (correlación de Pearson r entre 0,90 y 0,95). La correlación más baja es entre CYP3A4 y Lisozima ($r = 0,73$), lo que tiene sentido dado que sus mecanismos de reconocimiento son distintos. La figura de dispersión ΔG frente a peso molecular confirma la tendencia general: las moléculas más grandes se unen con mayor afinidad a todas las proteínas. Los fármacos modelo aparecen sistemáticamente en la zona de alta afinidad.




Figura 3.2: Mapa de correlación de Pearson entre las energías de docking (izquierda) y dispersión ΔG P-gp vs. TTR1 coloreada por grupo molecular ($r = 0,95$, derecha).




Figura 3.3: Energía de docking ΔG vs. peso molecular para las seis proteínas, coloreado por grupo molecular.

3.3. Análisis de interacciones proteína-ligando (PLIP)

El análisis de los 15 complejos generó 708 contactos no covalentes en total (figura siguiente). FR α , el receptor de folato que se sobreexpresa en tumores de ovario y mama, concentra la mayor parte: 515 contactos, de los que 340 son puentes de hidrógeno. Los residuos SER174 (67 contactos) y ARG103 (64) son los más implicados, y coinciden con los que la cristalografía describe como esenciales para reconocer el ácido fólico. Los puentes salinos con ASP81 y LYS136 en los oligómeros de quitosano sugieren que Chitotriose y Chitobiose se unen en el mismo bolsillo que el folato natural.

En P-gp, que es la principal bomba de expulsión de fármacos del organismo, 96 de los 100 contactos totales son hidrofóbicos, repartidos entre ILE730, LEU312, LEU757 y LEU760 (8 cada uno). Este patrón confirma lo que predice el análisis SHAP: P-gp reconoce sus sustratos por su forma y complejidad molecular, no por grupos químicos concretos. En TfR1, el receptor de transferrina que se usa para llevar moléculas al interior de células tumorales, aparecen 82 puentes de hidrógeno, con THR305 (10 contactos) y GLU972 (6) a la cabeza.




Figura 3.4: (Izquierda) Número de interacciones por tipo para cada proteína. (Derecha) Residuos con más contactos en FR α (4LRH).

3.4. Modelos de regresión de afinidad

Random Forest fue el mejor modelo en general (figura siguiente). $R^2 = 0,817$ en P-gp (MAE = 0,426 kcal/mol), 0,753 en TfR1 y 0,712 en Lisozima superan el umbral de 0,7 que se considera aceptable para modelos cuantitativos

de actividad. En CYP3A4 (0,62), FR α (0,53) y HSA (0,65) el rendimiento es más modesto. Con 56 muestras y validación cruzada de 5 particiones, cada fold de test tiene 11 moléculas, lo que limita la capacidad predictiva. Gradient Boosting fue competitivo en Tfr1 ($R^2 = 0,742$) y P-gp (0,746).

Los puntos con mayor error de predicción (outliers) en la figura de predicción vs. real son Paclitaxel y Condroitín sulfato disacárido en P-gp, probablemente porque su complejidad estructural está fuera del rango habitual del dataset. Ammonia es el principal outlier en Tfr1 por ser la molécula más pequeña del conjunto.




Figura 3.5: R^2 de los tres modelos de regresión en validación cruzada de 5 particiones. La línea roja marca el umbral $R^2 = 0,7$.




Figura 3.6: Predicción vs. real para P-gp MDR1 y TfR1, coloreado por grupo molecular.

3.5. Índice de Eficiencia de Transporte (ITI)

El ITI es una puntuación de 0 a 100 que resume en un solo número el perfil completo de una molécula para drug delivery: penaliza la afinidad por P-gp (expulsión) y CYP3A4 (metabolismo), y premia la afinidad por TfR1 y FR α (entrada en células tumorales), HSA (transporte en sangre) y lisozima (compatibilidad con tejidos).

El ranking (figura siguiente) lo encabeza Triethylene glycol (PEG, ITI=,100), seguido de Tetraethylenepentamine (87, 3), Pentaethylenhexamine (85, 0), Chitotriose (84, 7), Chitobiose (82, 7), D-Galactose (81, 7) y D-Mannose (81, 7). Los fármacos modelo quedan al final del dataset porque tienen alta afinidad por P-gp.




Figura 3.7: Top 20 moléculas por ITI (escala 0–100), coloreadas por grupo molecular.

La distribución por grupos (figura siguiente) muestra que ligandos de targeting y oligómeros tienen medianas alrededor de 70–72, los monómeros de degradación en torno a 60, y los fármacos modelo cerca de 42 con alta variabilidad. Los diagramas de radar muestran el patrón de Triethylene glycol: radio pequeño en P-gp y CYP3A4, moderado en Tfr1 y FR α .




Figura 3.8: Distribución del ITI por grupo molecular (boxplot + violin plot).




Figura 3.9: Perfil de afinidad de las moléculas 1–4 del ranking ITI. Mayor radio = mayor afinidad por esa proteína.




Figura 3.10: Perfil de afinidad de las moléculas 5–8 del ranking ITI.

3.6. Clasificador y valores SHAP

Gradient Boosting obtuvo $AUC-ROC = 0,983$, $Accuracy = 0,965$ y $F1 = 0,966$. Random Forest alcanzó $AUC = 0,978$ y $Accuracy = 0,932$. SVC obtuvo $AUC = 0,971$ y $Accuracy = 0,896$. Un AUC cercano a 1 significa que el modelo separa casi perfectamente moléculas favorables de desfavorables. Las curvas ROC con bandas de confianza se muestran en la figura siguiente.

El análisis SHAP muestra qué descriptores moleculares son los más importantes para predecir la afinidad por P-gp (figura siguiente). BertzCT, que mide la complejidad topológica de una molécula (cuántos caminos distintos hay en su grafo molecular), tiene un peso de 0,54, muy por encima de NumBonds (0,16), MW (0,14) y ExactMW (0,13). En la práctica, esto significa que P-gp expulsa moléculas complejas y grandes, sin importar mucho su química concreta.




Figura 3.11: Curvas ROC del clasificador en validación cruzada de 5 particiones.




Figura 3.12: Importancia de los 15 descriptores principales según SHAP para el modelo de P-gp MDR1.

3.7. Propiedades ADMET

El análisis ADMET con SwissADME (figura siguiente) mide propiedades farmacológicas clave: qué porcentaje de moléculas de cada grupo se absorbe bien en el intestino (GI absorption), cuántas son expulsadas por P-gp, y qué score de biodisponibilidad oral tienen.

Los monómeros de degradación tienen 0 violaciones de la regla de Lipinski (que define si una molécula puede ser un fármaco oral) y el 67, % con absorción intestinal alta. Los oligómeros presentan una media de 1,5 violaciones y 65, % de absorción. Los ligandos de targeting obtienen el mejor score de biodisponibilidad oral (BA $\approx$ 0,85) y 87, % de absorción. Los fármacos modelo tienen en media 1,75 violaciones, 20, % de absorción intestinal alta y el 80, % son sustratos de P-gp. Los monómeros de degradación no son sustratos de P-gp en ningún caso.




Figura 3.13: Propiedades ADMET por grupo molecular: violaciones Lipinski (izquierda), porcentaje de sustratos P-gp (centro) y biodisponibilidad oral vs. lipofilia (derecha).

Discusión

4.1. Geometrías DFT y perfiles sigma

Usar estructuras moleculares calculadas a nivel cuántico (DFT) en lugar de geometrías estimadas por métodos de campo de fuerza tiene un impacto real. Para moléculas grandes con tensión conformacional, como el sirolimus o el paclitaxel, las diferencias geométricas son suficientes para cambiar los perfiles sigma. Estos perfiles describen cómo se distribuye la polaridad en la superficie de la molécula, algo que los descriptores globales como LogP o TPSA no capturan con la misma precisión. Los estudios previos que calculan descriptores directamente desde SMILES asumen una geometría que puede estar lejos del mínimo real de energía.

4.2. Interpretación de los modelos

BertzCT domina el análisis SHAP con un peso de 0,54, frente a 0,16 de NumBonds y 0,14 de MW. Los tres miden, de distintas formas, el tamaño y la complejidad de la molécula. P-gp tiene un sitio de unión enorme, de unos 5000,Å³, y reconoce sus sustratos principalmente por su hidrofobicidad y complejidad topológica, no por grupos químicos específicos. Los resultados coinciden con lo que describe la literatura.

La correlación alta entre P-gp y Tfr1 ($r = 0,95$) tiene una implicación práctica importante: diseñar una molécula con alta afinidad por Tfr1 (para dirigirla a células tumorales) probablemente también aumentará su afinidad por P-gp (que la expulsará). Por eso el ITI es necesario. Una métrica que solo mida afinidad por Tfr1 no detecta ese conflicto.

El rendimiento moderado en CYP3A4 ($R^2 = 0,62$) y FR α ($R^2 = 0,53$) es esperable con 56 moléculas y validación cruzada de 5 particiones. Con 11 muestras de test por fold, cualquier modelo tiene margen limitado. Random Forest y Gradient Boosting funcionan razonablemente bien en estas condiciones.

4.3. Validación estructural con PLIP

Los 708 contactos identificados por PLIP dan contexto molecular a los resultados de docking. En FR α , los residuos SER174 (67 contactos) y ARG103 (64) son exactamente los que la cristalografía identifica como esenciales para reconocer el ácido fólico. Que los oligómeros de quitosano se unan en el mismo bolsillo sugiere que podrían funcionar como ligandos de targeting: FR α está sobreexpresado en tumores ováricos y de mama, así que una molécula que compita con el folato por ese sitio podría usarse para dirigir un nanocarrier específicamente a esos tumores.

En P-gp, los 96 contactos hidrofóbicos con ILE730, LEU312, LEU757 y LEU760 (8 cada uno) confirman lo que predice SHAP. Triethylene glycol y Tetraethylenepentamine forman muy pocos de esos contactos, lo que explica cuantitativamente por qué tienen ITI alto.

4.4. Relevancia del ITI y propiedades ADMET

Triethylene glycol (PEG, ITI=,100) tiene el perfil más limpio: 0 violaciones de Lipinski, biodisponibilidad oral alta y 0, % de sustrato P-gp. Las ramas PAMAM de baja generación (Tetraethylenepentamine con ITI=,87,3 y Pentaethylenhexamine con 85,0) combinan buena afinidad por TfR1 con poca interacción con P-gp.

El dato más directo viene del análisis ADMET: el 80, % de los fármacos modelo son sustratos de P-gp, frente al 0, % de los monómeros de degradación. Eso cuantifica el problema que resuelven los nanocarriers: si el fármaco está encapsulado en una partícula cuyo recubrimiento no es sustrato de P-gp, la bomba no puede expulsarlo directamente. Es una ventaja que los ensayos clínicos con formulaciones de nanopartículas PLGA y PAMAM han confirmado experimentalmente.

Chitotriose (ITI=,84,7) y Chitobiose (82,7) tienen un perfil equilibrado: buena afinidad por FR α confirmada por PLIP, poca interacción con P-gp

y pocas violaciones de Lipinski. El quitosano ya se usa ampliamente como recubrimiento de nanopartículas en formulaciones clínicas, así que estos resultados refuerzan lo que se observa experimentalmente.

4.5. Limitaciones

El tamaño del dataset es la limitación principal. Con 56 moléculas y cálculos DFT completos, el coste computacional es el factor que lo acota. La ausencia de validación experimental es inherente al carácter computacional del trabajo. Los valores de ΔG son coherentes con los publicados para moléculas similares, y los residuos identificados por PLIP coinciden con datos cristalográficos. Los pesos del ITI se definieron con criterio experto. Con datos de biodistribución real se podrían calibrar mejor.

Conclusiones

Se ha construido una plataforma computacional completa para evaluar componentes moleculares de nanopartículas poliméricas y dendrímeros frente a seis proteínas que determinan cómo se distribuye y metaboliza un fármaco en el organismo. Las conclusiones principales son:

1. Las 58 estructuras moleculares se optimizaron a nivel cuántico (B3LYP-D4/def2-TZVP) sin que ninguna presentara frecuencias imaginarias. Los perfiles de polaridad superficial (COSMO-RS) y las frecuencias de vibración IR se calcularon para todas las moléculas, incluidos los casos especiales como el cisplatino y el condroitín sulfato.
2. El protocolo de docking generó 342 resultados válidos frente a seis proteínas. La matriz de energías de unión resultante separa claramente fármacos, oligómeros y ligandos de targeting, con valores medios entre $-3,54$ y $-5,70$ kcal/mol según la proteína.
3. El análisis de interacciones con PLIP identificó 708 contactos no covalentes en 15 complejos. Los residuos clave de FR α (SER174, ARG103) y P-gp (ILE730, LEU312, LEU757) coinciden con los datos cristalográficos publicados, lo que valida las poses de docking obtenidas.
4. Random Forest superó $R^2 = 0,7$ en tres proteínas: P-gp ($R^2 = 0,817$, MAE = $0,426$ kcal/mol), TfR1 ($0,753$) y Lisozima ($0,712$). El conjunto de 2908 descriptores es suficientemente informativo para predecir la afinidad de unión con este dataset.
5. El ITI identifica Triethylene glycol (100), Tetraethylenepentamine (87,3), Pentaethylenehexamine (85,0), Chitotriose (84,7) y Chitobiose

- (82, 7) como los candidatos más favorables. Todos son componentes habituales en formulaciones de nanopartículas clínicas.
6. El análisis ADMET confirma que el 80, % de los fármacos modelo son sustratos de P-gp frente al 0, % de los monómeros de degradación. Ese contraste cuantifica el problema que resuelven los nanocarriers con ITI alto: al encapsular el fármaco, se reduce la exposición directa a la bomba de expulsión.
 7. El descriptor BertzCT, que mide la complejidad topológica de una molécula, tiene el mayor peso en el análisis SHAP (valor medio 0, 54), seguido de NumBonds (0, 16) y MW (0, 14). P-gp selecciona sus sustratos principalmente por tamaño y complejidad estructural, no por grupos químicos concretos.
 8. El clasificador binario alcanza $AUC-ROC = 0,983$ y $Accuracy = 0,965$. El espacio de descriptores moleculares separa bien las moléculas favorables de las desfavorables para drug delivery.
 9. La herramienta Streamlit permite evaluar cualquier molécula nueva introduciendo su SMILES: calcula descriptores, predice el perfil de afinidad, estima el ITI y recomienda el carrier más adecuado sin necesidad de ejecutar ningún script.

Líneas de trabajo futuro

El trabajo más evidente es ampliar el dataset. Con 200 a 500 moléculas, incluyendo generaciones superiores de PAMAM (G3-G5) y más variedad de ligandos de targeting, los modelos de regresión mejorarían notablemente. Con ese volumen de datos también sería posible probar arquitecturas de aprendizaje profundo como redes neuronales de grafos (GNN), que trabajan directamente con la estructura molecular en lugar de con descriptores numéricos calculados a mano.

La validación experimental es el paso que más valor daría a las predicciones. Ensayos de inhibición de P-gp, estudios de captación celular mediada por TfR1 o experimentos de biodistribución en animales permitirían comparar las energías de unión predichas con datos reales. Con esos datos también se podrían ajustar los pesos del ITI de forma empírica, en lugar de definirlos con criterio experto.

En cuanto al docking, aplicar métodos más precisos como FEP o MM-GBSA a los candidatos top del ITI daría una caracterización energética más fiable. Estos métodos son mucho más lentos que AutoDock Vina, pero para un conjunto reducido de candidatos son abordables.

La herramienta Streamlit tiene margen de mejora. Añadir un módulo de dibujo de estructuras moleculares directamente en el navegador, exportación de informes en PDF y conexión con bases de datos como PubChem o ChEMBL haría que fuera más útil para investigadores que no quieren trabajar con SMILES a mano.

Bibliografía

- Daina, A., Michielin, O., and Zoete, V. (2017). SwissADME: a free web tool to evaluate pharmacokinetics, drug-likeness and medicinal chemistry friendliness of small molecules. *Scientific Reports*, 7:42717.
- Danhier, F., Ansorena, E., Silva, J. M., Coco, R., Le Breton, A., and Préat, V. (2012). PLGA-based nanoparticles: An overview of biomedical applications. *Journal of Controlled Release*, 161(2):505–522.
- Eberhardt, J., Santos-Martins, D., Tillack, A. F., and Forli, S. (2021). Auto-Dock Vina 1.2.0: New docking methods, expanded force field, and python bindings. *Journal of Chemical Information and Modeling*, 61(8):3891–3898.
- Grimme, S., Antony, J., Ehrlich, S., and Krieg, H. (2010). A consistent and accurate ab initio parametrization of density functional dispersion correction (DFT-D) for the 94 elements H–Pu. *The Journal of Chemical Physics*, 132(15):154104.
- Kesharwani, P., Jain, K., and Jain, N. K. (2014). PAMAM dendrimers as efficient drug and gene delivery nanosystems for cancer therapy. *Colloids and Surfaces B: Biointerfaces*, 118:146–159.
- Lundberg, S. M. and Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30:4765–4774.
- Maingi, V., Kumar, M. V. S., Bhargava, B., and Maiti, P. K. (2012). Dendrimer building blocks in the presence of a physiological pH buffer: A computer simulation study. *The Journal of Physical Chemistry B*, 116(16):4968–4978.

- Moriwaki, H., Tian, Y.-S., Kawashita, N., and Takagi, T. (2018). Mordred: a molecular descriptor calculator. *Journal of Cheminformatics*, 10(1):4.
- RDKit (2023). RDKit: Open-source cheminformatics. Available from <https://www.rdkit.org>.
- Schake, P., Bolz, S. N., Linnemann, K., and Schroeder, M. (2025). PLIP 2025: introducing protein–protein interactions to the protein–ligand interaction profiler. *Nucleic Acids Research*, 53(W1):W463–W469.
- Trott, O. and Olson, A. J. (2010). AutoDock Vina: Improving the speed and accuracy of docking with a new scoring function, efficient optimization, and multithreading. *Journal of Computational Chemistry*, 31(2):455–461.
- TURBOMOLE GmbH (2023). TURBOMOLE v7.8.1. A development of University of Karlsruhe and Forschungszentrum Karlsruhe GmbH. Available from <http://www.turbomole.com>.
- Waghray, D. and Zhang, Q. (2018). Inhibit or evade multidrug resistance P-glycoprotein in cancer treatment. *Journal of Medicinal Chemistry*, 61(12):5108–5121.
- Weigend, F. and Ahlrichs, R. (2005). Balanced basis sets of split valence, triple zeta valence and quadruple zeta valence quality for H to Rn: Design and assessment of accuracy. *Physical Chemistry Chemical Physics*, 7(18):3297–3305.
- Zanger, U. M. and Schwab, M. (2013). Cytochrome P450 enzymes in drug metabolism: regulation of gene expression, enzyme activities, and impact of genetic variation. *Pharmacology & Therapeutics*, 138(1):103–141.